Slovenská technická univerzita v Bratislave
Fakulta informatiky a informačných technológií

FIIT-12345-123456

Bc. Peter Brandajský

Odolnosť modelov AI pre tvárovú biometriu voči adversariálnym útokom

Priebežná správa o riešení DP1

Vedúci diplomovej práce: Mgr. Ing. Emma Macháčová

Máj 2026

Slovenská technická univerzita v Bratislave
Fakulta informatiky a informačných technológií

FIIT-12345-123456

Bc. Peter Brandajský

Odolnosť modelov AI pre tvárovú biometriu voči adversariálnym útokom

Priebežná správa o riešení DP1

Študijný program:	Informačná bezpečnosť
Študijný odbor:	Informatika
Miesto vypracovania:	Ústav informatiky, informačných systémov a softvérového inžinierstva
Vedúci diplomovej práce:	Mgr. Ing. Emma Macháčová

Máj 2026

Don't forget to replace this page with your AIS assignment PDF by specifying `image("assignment.pdf")` into `assignment` argument of the template! Be careful, the assignment should be in PDF format, not just an image.

Typst 0.14 supports inserting PDFs with embedded text!

Čestne vyhlasujem, že som túto prácu vypracoval(a) samostatne, na základe konzultácií a s použitím uvedenej literatúry.

V Bratislave, 14.02.2026 .....

Bc. Peter Brandajský

Poďakovanie

I would like to thank my supervisor for all the help and guidance I have received. I would also like to thank my friends and family for supporting during this work.

Anotácia

Slovenská technická univerzita v Bratislave
FAKULTA INFORMATIKY A INFORMAČNÝCH TECHNOLÓGIÍ
Študijný program: Informačná bezpečnosť

Autor: Bc. Peter Brandajský
Priebežná správa o riešení DP1: Odolnosť modelov AI pre tvárovú biometriu voči adversariálnym útokom
Vedúci diplomovej práce: Mgr. Ing. Emma Macháčová
Máj 2026

Lorem ipsum dolor sit amet, consectetur adipiscing elit, sed do eiusmod tempor incididunt ut labore et dolore magnam aliquam quaerat voluptatem. Ut enim aeque doleamus animo, cum corpore dolemus, fieri tamen permagna accessio potest, si aliquod aeternum et infinitum impendere malum nobis opinemur. Quod idem licet transferre in voluptatem, ut postea variari voluptas distinguique possit, augeri amplificarique non possit. At etiam Athenis, ut e patre audiebam facete et urbane Stoicos irridente, statua est in quo a nobis philosophia defensa et collaudata est, cum id, quod maxime placeat, facere possimus, omnis voluptas assumenda est, omnis dolor repellendus. Temporibus autem quibusdam et aut officiis debitis aut rerum necessitatibus saepe eveniet, ut et voluptates repudiandae sint et molestiae non recusandae. Itaque earum rerum defuturum, quas natura non depravata desiderat. Et quem ad me accedis, saluto: 'chaere,' inquam, 'Tite!' lictores, turma omnis chorusque: 'chaere, Tite!' hinc hostis mi Albucius, hinc inimicus. Sed iure Mucius.

Annotation

Slovak Technical University in Bratislava
FACULTY OF INFORMATICS AND INFORMATION TECHNOLOGIES
Programme: Information Security

Author: Bc. Peter Brandajský
Interim report on DP1: Odolnosť modelov AI pre tvárovú biometriu voči adversariálnym útokom
Supervisor: Mgr. Ing. Emma Macháčová
May 2026

Lorem ipsum dolor sit amet, consectetur adipiscing elit, sed do eiusmod tempor incididunt ut labore et dolore magnam aliquam quaerat voluptatem. Ut enim aeque doleamus animo, cum corpore dolemus, fieri tamen permagna accessio potest, si aliquod aeternum et infinitum impendere malum nobis opinemur. Quod idem licet transferre in voluptatem, ut postea variari voluptas distinguique possit, augeri amplificarique non possit. At etiam Athenis, ut e patre audiebam facete et urbane Stoicos irridente, statua est in quo a nobis philosophia defensa et collaudata est, cum id, quod maxime placeat, facere possimus, omnis voluptas assumenda est, omnis dolor repellendus. Temporibus autem quibusdam et aut officiis debitis aut rerum necessitatibus saepe eveniet, ut et voluptates repudiandae sint et molestiae non recusandae. Itaque earum rerum defuturum, quas natura non depravata desiderat. Et quem ad me accedis, saluto: 'chaere,' inquam, 'Tite!' lictores, turma omnis chorusque: 'chaere, Tite!' hinc hostis mi Albucius, hinc inimicus. Sed iure Mucius.

Obsah

1 Úvod **1**

1.1 Motivácia 1

1.2 Prečo je tento problém dôležitý 1

1.3 Prečo ho treba riešiť 2

2 Prehľad súčasného stavu problematiky **3**

2.1 Biometria a rozpoznávanie tváre pomocou AI 3

2.2 Typy modelov pre rozpoznávanie tváre 3

2.3 Adversariálne útoky na rozpoznávanie tváre 4

2.3.1 Matematická formalizácia digitálnych útokov 5

2.3.2 Fyzické adversariálne útoky 6

2.3.3 Presentation útoky a detekcia 6

2.4 Obrany a robustnosť modelov 7

2.5 Metriky hodnotenia úspešnosti útokov 8

2.6 Medzery v stave poznania 8

3 Implementation **9**

Literatúra **11**

A Source code **A-1**

B Plán práce **B-1**

B.1 Semester I: DP I B-1

B.2 Semester II: DP II B-2

B.3 Semester III: DP III B-2

Zoznam obrázkov

Zoznam tabuliek

Kapitola 1

Úvod

1.1 Motivácia

Rozpoznávanie tváre, poháňané hlbokými neurónovými sieťami (Deep Learning), sa stalo dominantnou technológiou v oblasti biometrickej identifikácie. Tieto systémy sú čoraz častejšie nasadzované v kritických aplikáciách, ako sú riadenie prístupu, overovanie mobilných transakcií či zabezpečenie štátnych hraníc. Vysoká presnosť a rýchlosť moderných AI modelov však maskuje ich zásadnú slabinu: extrémne nízku robustnosť voči špeciálne skonštruovaným vstupom.

Problém, ktorý ideme riešiť, je kritická zraniteľnosť moderných AI modelov pre tvárovú biometriu voči adversariálnym útokom. Tieto útoky dokážu model oklamať pomocou nepatrných, často ľudským okom neviditeľných, modifikácií vstupného obrazu. Okrem digitálnych útokov (napr. Fast Gradient Sign Method – FGSM) je zvlášť nebezpečný scenár fyzických adversariálnych útokov (napr. masky, potlačené okuliare), kde je cieľom oklamať systém v reálnom prostredí.

1.2 Prečo je tento problém dôležitý

Dôvera v systémy informačnej bezpečnosti, ktoré sú postavené na AI, je priamo závislá od ich robustnosti. Ak môže neautorizovaná osoba získať prístup do chráneného priestoru alebo k citlivým dátam pomocou jednoduchej adversariálnej perturbácie, je narušená základná bezpečnostná funkcia. Je nevyhnutné pochopiť

a kvantifikovať tieto zraniteľnosti, aby bolo možné navrhnúť účinné obranné mechanizmy.

1.3 Prečo ho treba riešiť

Hoci teoretický výskum adversariálnych útokov existuje, chýba systematické porovnanie týchto útokov na rôznych, v praxi nasadených, biometrických modeloch pod rovnakými podmienkami. Zároveň je nedostatočne preskúmaná oblasť hybridných útokov, ktoré kombinujú digitálne a fyzické zraniteľnosti. Riešenie tohto problému prispeje k vývoju spoľahlivejších a robustnejších AI systémov a pomôže stanoviť relevantný benchmark pre ich bezpečnosť.

Kapitola 2

Prehľad súčasného stavu problematiky

2.1 Biometria a rozpoznávanie tváre pomocou AI

Biometrické systémy využívajú jedinečné fyziologické alebo behaviorálne charakteristiky človeka na autentifikáciu, pričom rozpoznávanie tváre patrí medzi najrozšírenejšie techniky v praxi vďaka bezkontaktnosti a používateľskému komfortu. V poslednom desaťročí došlo k výraznému posunu od klasických metód založených na ručne navrhnutých príznakoch k hlbokým neurónovým sieťam, ktoré dosahujú takmer ľudskú presnosť na štandardných benchmarkoch a umožnili nasadenie vo veľkom rozsahu v komerčných aj bezpečnostných aplikáciách [1], [2].

Moderné systémy na rozpoznávanie tváre typicky pozostávajú z modulov pre detekciu tváre, orezanie a normalizáciu, extrakciu vektorovej reprezentácie (embeddingu) a následné porovnanie s referenčnou databázou. Kľúčovým komponentom je práve model na extrakciu embeddingov, ktorý sa trénuje na veľkých datasetoch a jeho robustnosť voči rôznym typom útokov priamo ovplyvňuje bezpečnosť celej biometrickej schémy [3], [4].

2.2 Typy modelov pre rozpoznávanie tváre

V minulosti sa na rozpoznávanie tváre používali najmä klasické prístupy ako Eigenfaces alebo Local Binary Patterns Histograms (LBPH), ktoré pracovali s

lineárnymi alebo textúrnymi príznakmi a jednoduchšími klasifikátormi. Tieto metódy sú výpočtovo nenáročné, avšak v náročnejších podmienkach (zmena osvietenia, výraz tváre, čiastočné prekrytie) podstatne zaostávajú za deep learning modelmi, preto sa dnes uplatňujú skôr v jednoduchších alebo resource-constrained scenároch [3], [5].

S nástupom hlbokých konvolučných sietí sa presadil paradigm shift k modelom, ktoré mapujú tvár do embedding priestoru a optimalizujú stratu založenú na uhlovej alebo margin metriky, čo vedie k vysokej separovateľnosti identít. Medzi často používané open-source modely patria FaceNet, ArcFace, AdaFace a ich varianty, ktoré dosahujú veľmi vysokú presnosť na štandardných benchmarkoch, pričom existujú aj porovnania ukazujúce rozdiely v presnosti, robustnosti a výpočtových nárokoch jednotlivých architektúr [6], [7].

2.3 Adversariálne útoky na rozpoznávanie tváre

Adversariálne útoky využívajú malé, pre človeka často ťažko postrehnuteľné zmeny vstupu, ktoré spôsobia výraznú zmenu výstupu modelu, pričom pri rozpoznávaní tváre sa typicky rozlišujú útoky typu dodging (skrytie identity) a impersonation (vydávanie sa za inú identitu). Survey práce ukazujú, že hoci mnohé klasické útoky boli pôvodne navrhnuté pre všeobecné klasifikačné úlohy, boli úspešne adaptované aj na modely pre tvárovú biometriu, pričom sa riešia aj špecifiká, ako je porovnávacie rozhodovanie namiesto čistej klasifikácie [8].

Z hľadiska prostredia sa rozlišujú čisto digitálne útoky, kde sa modifikuje obraz pred spracovaním systémom, a fyzické útoky, pri ktorých útočník manipuluje reálny vzhľad (napr. okuliare, masky, potlač, svetelné vzory) tak, aby ich kamery zachytili ako adversariálne vzory. Štúdie zároveň ukazujú, že vlastnosti útokov ako transferabilita medzi modelmi, potreba znalosti parametrov modelu (white-box vs. black-box) či robustnosť v reálnom svete sú kľúčové faktory pri hodnotení praktickej nebezpečnosti adversariálnych techník voči tvárovej biometrike [8], [9].

2.3.1 Matematická formalizácia digitálnych útokov

Digitálne adversariálne útoky možno formálne definovať ako optimalizačný problém, ktorého cieľom je nájsť minimálnu perturbáciu δ, ktorá po pripočítaní k vstupnému obrázku x spôsobí nesprávnu klasifikáciu modelu f. Nech $f(x)$ je neurónová sieť a y je skutočná trieda (identita) vstupu x. Cieľom útoku je nájsť modifikovaný vstup $x_{\text{adv}} = x + \delta$ tak, aby platilo $f(x_{\text{adv}}) \neq y$, pričom veľkosť perturbácie je ohraničená normou $\|\delta\|_p < \varepsilon$. Toto ohraničenie zabezpečuje, že zmena zostane pre ľudského pozorovateľa vizuálne nepostrehnuteľná [10].

V kontexte testovania robustnosti biometrických modelov sa za štandard považujú gradientové metódy, ktoré využívajú informáciu o gradiente stratovej funkcie na konštrukciu perturbácie. Medzi najvýznamnejšie z nich patria Fast Gradient Sign Method (FGSM) a jej iteratívny variant Projected Gradient Descent (PGD).

Fast Gradient Sign Method (FGSM) FGSM je jednokrokový útok, ktorý využíva gradient stratovej funkcie $J(\theta, x, y)$ vzhľadom na vstupný obrázok na určenie smeru, v ktorom sa chyba modelu maximalizuje najrýchlejšie. Adversariálny príklad sa vypočíta podľa vzťahu:

$$x_{\text{adv}} = x + \varepsilon \cdot \text{sign}(\nabla_x J(\theta, x, y))$$

kde θ sú parametre modelu, ε je sila útoku a funkcia $\text{sign}(\cdot)$ zabezpečuje maximálnu zmenu pixelu v rámci ohraničenia L_∞ normy. Hoci je FGSM výpočtovo efektívny, predpokladá linearitu rozhodovacej hranice, čo môže limitovať jeho účinnosť voči komplexnejším modelom [10].

Projected Gradient Descent (PGD) PGD predstavuje silnejší, iteratívny prístup k generovaniu útokov a je považovaný za univerzálny útok prvého rádu. Metóda aplikuje princíp FGSM opakovane v menších krokoch α, pričom po každom kroku projektuje výsledok späť do povolenej ε-gule (okolia pôvodného obrázka), čím sa zaručí dodržanie vizuálnej podobnosti. Aktualizačné pravidlo v t-tej iterácii je definované ako:

$$x^{t+1} = \Pi_{x+S}(x^t + \alpha \cdot \text{sign}(\nabla_x J(\theta, x^t, y)))$$

kde Π_{x+S} označuje operáciu projekcie na množinu povolených perturbácií S. Vďaka iteračnému hľadaniu optima dosahuje PGD výrazne vyššiu úspešnosť než jednokrokové metódy a slúži ako etalón pre hodnotenie bezpečnosti neurónových sietí [11].

2.3.2 Fyzické adversariálne útoky

Fyzické adversariálne útoky na systémy rozpoznávania tváre spočívajú v manipulácii reálneho vzhľadu útočníka tak, aby kamery zachytili obraz, ktorý mätie AI modely za účelom zmeny autentifikácie. Medzi bežné fyzické útoky patria okuliare s nepravidelnými vzormi, 3D masky, špeciálny make-up či potlačené náplasti, ktoré sú navrhnuté tak, aby boli pre človeka relatívne nenápadné, no efektívne mýlili deep learning modely tvárového rozpoznávania. Tieto útoky môžu spôsobiť buď dodging (vyhýbanie sa rozpoznaniu) alebo impersonation (vydávanie sa za inú osobu). Novšie techniky ako napríklad „invisible“ laserové okuliare ukazujú rastúci trend sofistikovaných spôsobov fyzických útokov, ktoré sú stále náročnejšie na detekciu a vyššie úrovne obrany. Robia tak používaniu biometrickej autentifikácie rizikovejším v reálnych podmienkach [9], [12].

2.3.3 Presentation útoky a detekcia

Presentation attacks predstavujú špecifický spôsob podvodu, pri ktorom útočník systému „predkladá“ falošný alebo upravený biometrický vzor, napríklad fotografiu, video na displeji, realistickú masku alebo iný vizuálny artefakt, s cieľom obísť autentifikáciu založenú na tvári. Ochrana proti týmto útokom je predmetom oblasti presentation attack detection (PAD), ktorá využíva rôzne metódy vrátane analýzy textúry, detekcie živosti, analýzy pulzov, alebo hlbokých neurónových sietí trénovaných na rozlíšenie medzi živou tvárou a prezentovaným artefaktom. Efektívna PAD je nevyhnutná pre zabezpečenie spoľahlivosti tvárovej biometrie, no stále existujú útoky, ktoré dokážu PAD preliezť, čo vyžaduje ďalší výskum a experimentálnejšie overenia [9], [13].

2.4 Obrany a robustnosť modelov

Výskum obrany proti adversariálnym útokom na rozpoznávanie tváre zahŕňa jednak úpravy samotných modelov (adversariálne trénovanie, regularizácia, robustné straty), jednak doplnkové moduly na detekciu podozrivých vstupov pred ich spracovaním. Pre tvárovú biometriu sa skúmajú aj špecializované prístupy využívajúce štruktúru tváre, viacnásobné snímky alebo kombináciu rôznych modalít, ktoré zvyšujú odolnosť voči útokom, no často za cenu vyššej výpočtovej náročnosti alebo zhoršeného používateľského komfortu [8], [9], [13].

Napriek rôznym navrhovaným obranám pretrváva problém tzv. adaptive attacks, pri ktorých útočník pri návrhu útoku priamo zohľadňuje konkrétnu obranu, čo v praxi často vedie k jej obchádzaniu. Najnovšie práce preto odporúčajú hodnotiť robustnosť systémov rozpoznávania tváre v ucelených rámcoch, ktoré kombinujú rôzne typy útokov (digitálne aj fyzické), rôzne modely a rôzne scenáre znalostí útočníka (white-box, gray-box, black-box)[8], [9].

S nárastom sofistikovanosti adversariálnych útokov sa výskum zameriava na vývoj robustných obranných mechanizmov. Tieto techniky možno rozdeliť do troch hlavných kategórií:

1. Adversariálne trénovanie (Adversarial Training): Proces, pri ktorom sa do trénovacej množiny zámerne vkladajú adversariálne príklady. Model sa tak učí správne klasifikovať aj perturbované vstupy, čím sa zvyšuje jeho robustnosť voči útokom typu PGD [11].

2. Preprocessing a čistenie vstupu: Metódy, ktoré sa pokúšajú odstrániť adversariálny šum z obrázka pred jeho klasifikáciou, napríklad pomocou stratovej kompresie JPEG alebo vyhladzovacích filtrov [11].

3. Detekcia útokov: Samostatné modely alebo štatistické metódy, ktoré identifikujú, či vstupný obrázok vykazuje znaky neprirodzenej manipulácie, bez toho, aby sa ho snažili klasifikovať [11].

2.5 Metriky hodnotenia úspešnosti útokov

Pre kvantitatívne vyhodnotenie efektivity útokov na tvárovú biometriu sa využívajú špecifické metriky:

- Attack Success Rate (ASR): Percentuálny podiel útokov, ktoré viedli k úspešnému oklamaniu modelu (napr. zmena predikcie identity) [14].
- Miera transferability: Schopnosť adversariálneho príkladu vygenerovaného pre jeden model (white-box) oklamať iný, neznámy model (black-box). Táto vlastnosť je kľúčová pre praktickú realizovateľnosť útokov v reálnom svete [10].
- L-normy (Distance Metrics): Merajú mieru vizuálnej perturbácie. Najčastejšie využívaná L∞ norma obmedzuje maximálnu zmenu jednotlivého pixelu, zatiaľ čo L2 norma meria celkovú euklidovskú vzdialenosť medzi pôvodným a upraveným obrázkom [1], [2], [15].

2.6 Medzery v stave poznania

Aj keď existuje viacero survey článkov o adversariálnych útokoch na rozpoznávanie tváre a o presentation attack detection, stále chýbajú systematické porovnania, ktoré by v jednotnom experimente hodnotili viacero reprezentatívnych digitálnych aj fyzických útokov na rôznych typoch modelov (open-source embedding modely vs. jednoducho trénované vlastné architektúry). Navyše, mnohé práce sa sústreďujú len na jeden typ útoku alebo jednu triedu modelov, takže otázka, ktoré kombinácie útok–model sú v praxi najnebezpečnejšie a aké sú ich limity v reálnych podmienkach, zostáva čiastočne otvorená [8], [9], [12], [13].

Kapitola 3

Implementation

Literatúra

[1] M. Wang a W. Deng, "Deep Face Recognition: A Survey", *Neurocomputing*, zv. 429, 2020, doi: 10.1016/j.neucom.2020.10.081.

[2] X. Wang, P. Jiang, S. Zhang, B. Chen, Y. Wang, a Y. Guo, "A Survey of Face Recognition", *arXiv (Cornell University)*, 2022, doi: 10.48550/arxiv.2212.13038.

[3] S. R, A. P. Mulgund, S. Hiremath, S. H. A, a A. K. Koundinya, "Comparative Analysis of Traditional and Machine Learning Based Face Recognition Models", s. 1–6, 2023, doi: 10.1109/icdds59137.2023.10434381.

[4] A. Ali-Gombe, E. Elyan, a J. Zwiegelaar, "Towards a Reliable Face Recognition System", *Proceedings of the International Neural Networks Society*, s. 304–316, 2020, doi: 10.1007/978-3-030-48791-1_23.

[5] M. A. Faqih, Hendrawan, E. Mulyana, a W. Hermawan, "On the Performance of Face Recognition Models for Local Faces Dataset", *2023 17th International Conference on Telecommunication Systems, Services, and Applications (TSSA)*, s. 1–4, 2023, doi: 10.1109/tssa59948.2023.10366896.

[6] A. Firmansyah, T. F. Kusumasari, a E. N. Alam, "Comparison of Face Recognition Accuracy of ArcFace, Facenet and Facenet512 Models on Deepface Framework", 2023, doi: 10.1109/iccosite57641.2023.10127799.

[7] R. Sony, P. Farmanifard, A. Ross, a A. K. Jain, "Foundation versus Domain--specific Models: Performance Comparison, Fusion, and Explainability in

Face Recognition". Cit: 25. november 2025. [Online]. Dostupné na: https://arxiv.org/abs/2507.03541

[8] F. Vakhshiteh, A. Nickabadi, a R. Ramachandra, "Adversarial Attacks against Face Recognition: A Comprehensive Study". Cit: 26. november 2025. [Online]. Dostupné na: https://arxiv.org/abs/2007.11709

[9] M. Wang, J. Zhou, T. Li, G. Meng, a K. Chen, "A Survey on Physical Adversarial Attacks against Face Recognition Systems". Cit: 26. november 2025. [Online]. Dostupné na: https://arxiv.org/abs/2410.16317

[10] I. J. Goodfellow, J. Shlens, a C. Szegedy, "Explaining and Harnessing Adversarial Examples". Cit: 11. február 2025. [Online]. Dostupné na: https://arxiv.org/abs/1412.6572

[11] A. Madry, A. Makelov, L. Schmidt, D. Tsipras, a A. Vladu, "Towards Deep Learning Models Resistant to Adversarial Attacks", *arXiv:1706.06083 [cs, stat]*, 2019, doi: 10.48550/arXiv.1706.06083.

[12] Y. Wang, Z. Liu, B. Luo, R. Hui, a F. Li, "The Invisible Polyjuice Potion: an Effective Physical Adversarial Attack against Face Recognition", s. 3346–3360, 2024, doi: 10.1145/3658644.3670382.

[13] M. Pooshideh *et al.*, "Presentation Attack Detection: A Systematic Literature Review", *ACM Computing Surveys*, zv. 57, s. 1–32, 2024, doi: 10.1145/3687264.

[14] N. Akhtar a A. Mian, "Threat of Adversarial Attacks on Deep Learning in Computer Vision: A Survey", *IEEE Access*, zv. 6, s. 14410–14430, 2018, doi: 10.1109/access.2018.2807385.

[15] N. Carlini a D. Wagner, "Towards Evaluating the Robustness of Neural Networks", *arXiv:1608.04644 [cs]*, 2017, Cit: 14. február 2026. [Online]. Dostupné na: https://arxiv.org/abs/1608.04644

Príloha A

Source code

Príloha B

Plán práce

B.1 Semester I: DP I

Fáza	Úloha	Očakávané výstupy
Teória	Vypracovanie podrobného prehľadu aktuálnych techník rozpoznávania tváre pomocou AI (Deep Learning modely).	Dokončená textová časť k Sekcii 2 (Prehľad súčasného stavu) a jej rozšírenie o najnovšie práce.
Útoky	Klasifikácia a analýza digitálnych, fyzických a Presentation Attacks (PAD) relevantných pre modely tvárovej biometrie.	Detailný popis vybraných útokov (napr. FGSM, PGD, print attacks, masky) na implementáciu.
Model	Návrh a implementácia vlastného, jednoduchšieho modelu rozpoznávania tváre (benchmark model).	Funkčný vlastný CNN model pre porovnanie s open-source modelmi (Téza B).
Prostredie	Príprava experimentálneho prostredia a integrácia open-source modelov (FaceNet, ArcFace, AdaFace).	Experimentálne prostredie pripravené na testovanie digi tálnych útokov.

B.2 Semester II: DP II

Fáza	Úloha	Očakávané výstupy
Testovanie A	Systematické otestovanie a porovnanie účinnosti vybraných digitálnych útokov (FGSM, PGD) na open-source i vlastnom modeli.	Kvantitatívne výsledky (úspešnosť, transferabilita) pre digitálne útoky (podpora Téz A a B).
Testovanie B	Overenie efektivity fyzických a presentation attacks (simulovaných alebo reálnych) na všetkých vybraných modeloch.	Dáta o účinnosti fyzických/ PAD útokov a detekčných mechanizmov (podpora Tézy C).
Návrh	Návrh nového hybridného adversariálneho útoku, ktorý kombinuje digitálne a fyzické perturbácie.	Detailný teoretický návrh útoku s popisom implementácie (podpora Tézy D).
Implementácia útoku	Implementácia navrhnutého hybridného útoku.	Funkčná kódová báza nového útoku.

B.3 Semester III: DP III

Fáza	Úloha	Očakávané výstupy
Vyhodnotenie útoku	Experimentálne vyhodnotenie efektívnosti navrhnutého hybridného útoku proti obranným mechanizmom (napr. adversariálne trénovanie, PAD).	Experimentálne overenie útoku a jeho účinnosti (podpora Tézy D).
Analýza a Doporučenia	Komplexná analýza všetkých experimentálnych výsledkov a sformulovanie doporučení pre zvýšenie odolnosti tvárových biometrických systémov.	Záverečné doporučenia pre robustnosť a smerovanie ďalšieho výskumu.

Fáza	**Úloha**	**Očakávané výstupy**
Dokumentácia	Spracovanie finálnej textovej verzie diplomovej práce, revízia a formalizácia.	Diplomová práca v súlade s pokynmi fakulty.